



# 本节知识点概述

## 爬取知乎关注者信息

### 爬虫的一般思路

抓取网页  
解析网页  
储存数据

### 实战环节

分析知乎  
动手写爬虫



# 爬虫的一般思路

1

抓取网页、分析请求。

2

解析网页、寻找数据。

3

储存数据、多页处理。




DC学院  
class.pkbigdata.com

造数

# 分析具体网页

[http://www.zkh360.com/zkh\\_catalog/3.html](http://www.zkh360.com/zkh_catalog/3.html)

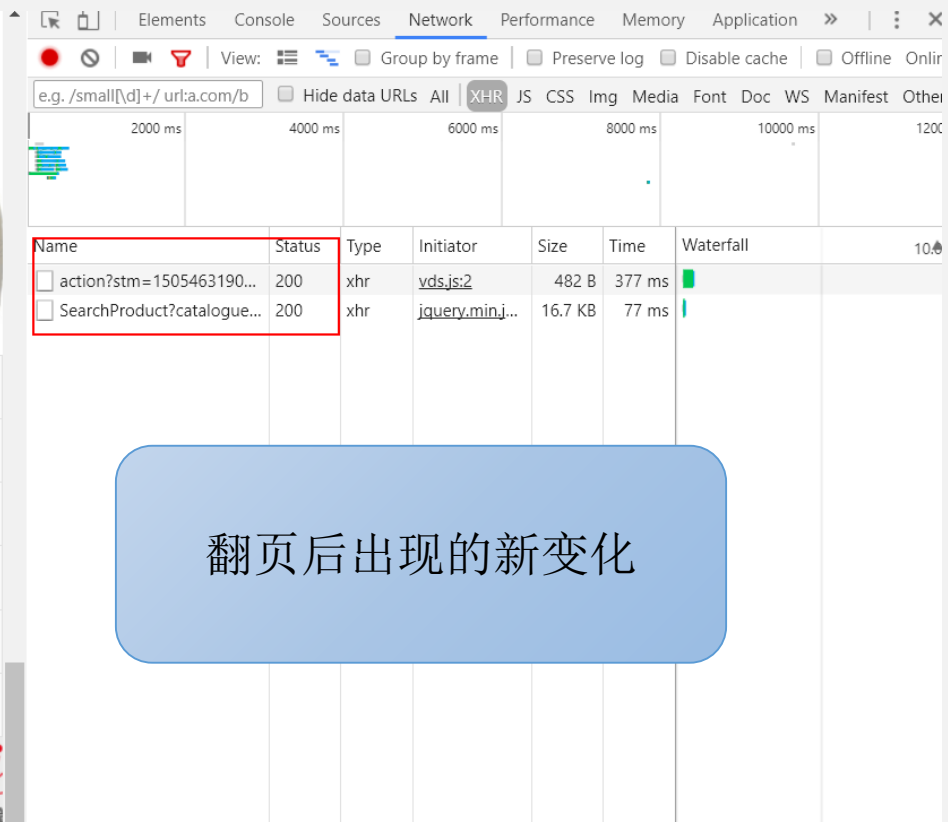


翻页后URL不变  
如何寻找请求？

哪些网站也是这样？




# 使用Chrome





# 如何寻找真实的请求



尝试寻找  
淘宝的请求



DC学院  
class.pkbigdata.com

造数



# 实战环节

<https://www.zhihu.com/people/excited-vczh/following>

动态

回答 16484

提问 492

文章 71

专栏 5

想法 0

更多

+ 关注他

发私信

**指尖要高冷**  
微博：指尖要高冷  
15 回答 · 0 文章 · 2909 关注者

+ 关注她

**joykiller**  
码农，爱好物理，业余养鱼  
8 回答 · 0 文章 · 775 关注者

+ 关注

**姜啾叽**  
2 回答 · 0 文章 · 676 关注者

+ 关注她

**卢卢卢**  
武大 英国留学 篮球 健身 摄影 超级英雄迷 微博:四南  
4 回答 · 0 文章 · 245 关注者

+ 关注她

**韩可爱**  
微博：新得乐啦 /常驻韩国/韩国美妆/韩国旅游/韩国美食  
23 回答 · 20 文章 · 3244 关注者

+ 关注

**没有脑子**  
胆小  
45 回答 · 0 文章 · 36 关注者

+ 关注她

知乎收录 4 个回答

编辑推荐收录

获得 1509366 次赞同

获得 185843 次感谢，247117 次收藏

参与 2406 次公共编辑

关注了 2299

关注者 601957

赞助的 Live

6

关注的话题

34

关注的专栏

75

关注的问题

27547

关注的收藏夹

21

刘看山 · 知乎指南 · 知乎协议 · 应用 · 工作

侵权举报 · 网上有害信息举报专区

违法和不良信息举报：010-82716601

儿童色情信息举报专区

联系我们 © 2017 知乎

寻找请求

DC学院 | 造数  
class.pkbigdata.com



# 动手写爬虫

## 知乎请求头信息

▼ Request Headers [view source](#)

```
accept: application/json, text,
Accept-Encoding: gzip, deflate,
Accept-Language: zh-CN,zh;q=0.
authorization: Bearer Mi4xUUhNc0
7|b43e672333e0fe298111f2b18ed
Connection: keep-alive
Cookie: d_c0="AJAC1bp8MQyPTvIc
7962.1502441667; _xsrp=cf9ef5i
0; aliyungf_tc=AQAAAPRDWmS6EA
5ea2e42c1a1d5ff217b1c0fa09c9b
d2d2db42baf3c904a9"; __utma=5
=51854390; __utmz=51854390.15i
e=20170809=1; z_c0=M14xUUhNc0
|b43e672333e0fe298111f2b18ed9
Host: www.zhihu.com
Referer: https://www.zhihu.com/
User-Agent: Mozilla/5.0 (Windor
X-UDID: AJAC1bp8MQyPTvIcjXY7p
```

找不同

## 常见的请求头

Accept:  
Accept-Encoding:  
Accept-Language:  
Connection:  
Cookie:  
Host:  
Referer:  
User-Agent:



DC学院  
class.pkbigdata.com

造数



# 保存单网页信息

```
# -*- coding:utf-8 -*-  
  
import requests  
import pandas as pd  
  
headers = {  
    'authorization': 'Bearer Mi4xUUhNc0FnQUFBQUFBa0FLVnVud3hEQmNBQUFCaEFsVk5oeW5qV1FBcmVhY2F0VUhhWenJTc1hVcUlycW1tRzAtMXpB|1505467527|b43e672333e0fe298111f2b18ed9e52c9f8f23d7',  
    'User-Agent': 'Mozilla/5.0 (Windows NT 10.0; WOW64) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/62.0.3192.0 Safari/537.36',  
}  
  
url = 'https://www.zhihu.com/api/v4/members/excited-vczh/followees?offset=0&limit=20'  
r = requests.get(url, headers=headers).json()  
  
df = pd.DataFrame.from_dict(r['data'])  
df.to_csv('users.csv')
```

设置请求头

获得数据

保存数据



DC学院  
class.pkbigdata.com

造数





# 保存多页

```
# -*- coding:utf-8 -*-  
  
import requests  
import pandas as pd  
import time  
  
headers = {  
    'authorization': 'Bearer Mi4xUUhNc0FnQUFBQUFBa0FLVnVud3hEQmNBQUFCaEFsVk5oeW5qV1FBcmVhY2F0VUhwZWJhc1hVcUlycW1tRzAtMXpB|'\n    '1505467527|b43e672333e0fe298111f2b18ed9e52c9f8f23d7',  
    'User-Agent': 'Mozilla/5.0 (Windows NT 10.0; WOW64) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/62.0.3192.0 Safari/537.36',  
}  
  
user_data = []  
  
def get_user_data(page):  
    for i in range(page):  
        url = 'https://www.zhihu.com/api/v4/members/excited-vczh/followees?offset={}&limit=20'.format(i*20)  
        response = requests.get(url, headers=headers).json()  
        user_data.extend(response['data'])  
        print("成功爬取第%s页" % str(i+1))  
        time.sleep(1)  
  
if __name__ == '__main__':  
    get_user_data(8)  
    df = pd.DataFrame.from_dict(user_data)  
    df.to_csv('user.csv')
```

翻页处理

暂停爬虫

调用函数



DC学院  
class.pkbigdata.com

造数





# 完成作业

- 查看淘宝的翻页
- 将vczh改为其他人
- 尝试爬取知乎粉丝信息



DC学院  
class.pkbigdata.com

造数

# 爬虫工程师

更多数据科学课程，上DC学院：[class.pkbigdata.com](http://class.pkbigdata.com)



关注 DataCastle



关注造数

造数